

# Análise Computacional de Jogos Estocásticos Cooperativos e Não Cooperativos

Natan da Silveira Ferreira      Nicolas da Silva Wischermann

Novembro de 2025

## Parte 1 - Compreendendo o ambiente

### Definição do Modelo e Matrizes de Payoff

A função `queuedefs()` define o modelo completo do jogo estocástico:

- **Parâmetros do sistema:** estados de canal (NS), tamanhos de buffer (NB), ações de potência (NA) e admissão (NB.adm)
- **Transições de canal:** Cadeia de Markov (PL) modelando qualidade do canal
- **Transições de fila:** Matriz P modelando dinâmica do buffer (chegadas/saídas)

### Matrizes c1 e c2

As matrizes  $C_1$  e  $C_2$  representam, respectivamente, as recompensas dos jogadores 1 e 2, dadas pelo conjunto:

(estado\_jogador\_1, ação\_jogador\_1, estado\_jogador\_2, ação\_jogador\_2)

E mudam conforme o modo:

- **Zero-Sum** (adversarial):

$$\begin{aligned}c1[i, a, j, b] &= \log_2(1 + \text{SINR}_1) \\c2[i, a, j, b] &= -c1 \quad (\text{ganho de um é perda do outro})\end{aligned}$$

- **Non-Cooperative** (Nash):

$$\begin{aligned}c1[i, a, j, b] &= \log_2(1 + \text{SINR}_1) \\c2[i, a, j, b] &= \log_2(1 + \text{SINR}_2) \quad (\text{cada um maximiza seu próprio throughput})\end{aligned}$$

- **Cooperative** (Team):

$$c1 = c2 = \log_2(1 + \text{SINR}_1) + \log_2(1 + \text{SINR}_2) \quad (\text{maximizam throughput agregado})$$

### Solução via Programação Linear (Best-Response)

Para cada jogador  $i \in \{1, 2\}$ , resolver o melhor-resposta contra a estratégia do oponente:

$$\max_{\rho_i} \mathbb{E}_{\rho_i, \rho_{-i}}[R_i] \quad \text{sujeito a:}$$

1. Equações de balanço de fluxo (distribuição estacionária):

$$\sum_{a,b} \rho_i(x, a, b) = \sum_{x'} P_L(x', x) \sum_{j', a', b'} \rho_i(x', a', b') P_Q(j', a', b', j)$$

2. Normalização (probabilidade):

$$\sum_{x,a,b} \rho_i(x, a, b) = 1$$

3. Limite de potência média:

$$\mathbb{E}_{\rho_i}[a] = \sum_{x,a,b} a \cdot \rho_i(x, a, b) \leq v_i$$

A função `queuestr_lp()` resolve o problema de um jogador contra a estratégia fixa do oponente:

- **Entrada:** estratégia (occupation measure) do oponente
- **Objetivo:** maximizar throughput esperado do jogador
- **Restrições:**
  - Equações de balanço de fluxo (1)
  - Limite de potência média (3)
  - Admissão válida apenas com buffer não-vazio
- **Saída:** occupation measure ótima  $\rho$  (probabilidade de estado-ação)

## Algoritmo Iterativo de Best-Response

A função `queuesolvegame.py()` encontra o equilíbrio (Nash ou Team) iterativamente:

1. **Inicialização:** política heurística ou uniforme para ambos jogadores
2. **Iteração:** cada jogador calcula best-response contra estratégia atual do outro
3. **Convergência:** para quando valores ( $\text{val1}, \text{val2}$ ) estabilizam ( $\varepsilon < 10^{-10}$ )
4. **Resultado:** equilíbrio de Nash (non-coop) ou solução de time (coop)

**Nota:** Corrigimos um bug de propagação do `CostFunction`; agora o best-response respeita corretamente os modos Zero-Sum, Non-Coop e Cooperative.

## Experimentos: Comparaçāo dos Três Modos de Jogo

Executamos o modelo com parâmetros idênticos em três configurações:

1. **Zero-Sum:** jogo adversarial (conflito total)
2. **Non-Cooperative:** equilíbrio de Nash (cada um por si)
3. **Cooperative:** problema de time (cooperação total)

Para cada modo, calculamos políticas ótimas de potência e admissão, e avaliamos o throughput físico agregado.

## Resumo resultados iniciais

- **Zero-Sum** limita o throughput conjunto (valores simétricos e menores), como esperado pelo conflito total
  - **Non-Coop** entrega throughput intermediário; cada jogador optimiza o próprio ganho
  - **Cooperative** maximiza o throughput agregado, superando os outros modos
1. Descreva qualitativamente o significado das matrizes  $C_1$  e  $C_2$  e como elas mudam entre os modos.

## Parte 2

O equilíbrio de Nash é formulado como um Problema de Complementaridade Linear (LCP): encontrar vetor  $x \geq 0$  tal que  $Mx + q \geq 0$  e  $x^T(Mx + q) = 0$ .

### Definição de $x$ , $M$ e $q$

O vetor  $x$  concatena as estratégias ( $\rho$ ) e os multiplicadores de Lagrange de igualdade ( $\lambda$ ) e desigualdade ( $\mu$ ) para ambos os jogadores:

$$x = [\rho_1^T, \rho_2^T, \lambda_1^T, \lambda_2^T, \mu_1^T, \mu_2^T]^T$$

A matriz  $M$  e o vetor  $q$  unificam as condições de otimalidade e viabilidade:

$$M = \begin{pmatrix} 0 & -C_1 & E_1^T & 0 & K_1^T & 0 \\ -C_2 & 0 & 0 & E_2^T & 0 & K_2^T \\ -E_1 & 0 & 0 & 0 & 0 & 0 \\ 0 & -E_2 & 0 & 0 & 0 & 0 \\ -K_1 & 0 & 0 & 0 & 0 & 0 \\ 0 & -K_2 & 0 & 0 & 0 & 0 \end{pmatrix}, \quad q = \begin{pmatrix} \mathbf{0} \\ \mathbf{0} \\ \beta_1 \\ \beta_2 \\ L_1 \\ L_2 \end{pmatrix}$$

Onde os componentes representam:

- $C_1, C_2$ : Matrizes de payoff (versão achatada dos tensores).
- $E, \beta$ :  $E$  contém as equações de fluxo ( $\delta - P$ ) e uma última linha preenchida com 1s para somar as probabilidades.  $\beta = [0, \dots, 0, 1]^T$  define os alvos: fluxo líquido nulo e probabilidade total unitária.
- $K, L$ :  $K$  é a matriz de custos composta por duas linhas: custos de potência  $d(x, a)$  e tamanhos de fila  $j$ .  $L = [v, B_{\max}]^T$  contém os limites superiores.
- $\mathbf{0}$ : Vetor nulo com dimensão igual ao número de variáveis, resultante da derivada parcial do Lagrangiano em relação a  $\rho$ .

## Implementação Numérica

Nós tentamos resolver o LCP usando tanto a biblioteca `lemkelcp` quanto a `quantecon`, mas o algoritmo não convergiu em nenhum dos dois casos.

## Parte 3

A inclusão da restrição  $\mathbb{E}[\text{Backlog}] \leq B_{\max}$  impactou principalmente três componentes do código:

- **Classe Settings**: Adicionamos o atributo `BMAX`: `int` à classe `Settings`, podendo ser inicializado como por exemplo:

```
BMAX: int = 10
```

Este valor define o limite máximo permitido para o backlog médio.

- **Função queuedefs(s)**: A linha `BMAX = s.BMAX` foi adicionada ao dicionário `defs` retornado, garantindo que o valor seja repassado ao processo de otimização.

- **Função queestr\_lp(for\_player, rho\_other, defs)**: Esta foi a função mais impactada, pois formula e resolve o problema de Programação Linear. As modificações incluem:

1. Recuperação de  $B_{\max}$  através de `BMAX = defs['BMAX']`;
2. Criação de um novo conjunto de coeficientes para  $A_{ub}$  e  $b_{ub}$ , que implementam a restrição linear:

$$\sum j \cdot \rho[i, j, a, b] \leq B_{\max};$$

3. Combinação dessa restrição com as já existentes utilizando `np.vstack` e `np.concatenate`;
4. Impressão do valor real obtido do backlog médio (`actual_backlog`), possibilitando verificar a proximidade com o limite  $B_{\max}$ .

## Análise comparativa em função de $B_{\max}$

Observa-se que, na ausência de restrição sobre o número médio de pacotes no buffer, as políticas de admissão tendem a sempre aceitar novos pacotes. Isso ocorre porque o eixo horizontal dos gráficos — que representa o estado do buffer — varia de 0 a  $N_{\text{BufferState}} - 1$ , o que corresponde a um recorte que não exibe explicitamente as rejeições que ocorreriam quando o buffer ultrapassa seu limite físico.

Ao introduzir a restrição sobre o número médio de pacotes no buffer por meio de  $B_{\max}$ , torna-se evidente o comportamento mencionado: o agente passa a rejeitar novos pacotes quando o backlog excede a média permitida por certo limiar.

Nas figuras a seguir, apresentamos as políticas de admissão considerando  $B_{\max} = 1$  e  $B_{\max} = 4$ . Embora existam pequenas variações decorrentes das diferentes funções de perda utilizadas, observa-se claramente que a restrição sobre o número médio de pacotes impõe um limite inferior, em relação a  $N_{\text{BufferState}}$ , para a decisão de aceitar ou rejeitar novos pacotes, conforme esperado.

latex




Figure 1: Zero-Sum com  $B_{\max} = 1$




Figure 2: Zero-Sum com  $B_{\max} = 4$




Figure 3: Non-Cooperative com  $B_{\max} = 1$




Figure 4: Non-Cooperative com  $B_{\max} = 4$




Figure 5: Cooperative com  $B_{\max} = 1$




Figure 6: Cooperative com  $B_{\max} = 4$

Conforme observado e comprovado por meio do notebook experimental, quando  $B_{\max} > N_{\text{BufferState}}$ , a solução degenera para o caso sem a restrição

$$\mathbb{E}[\text{Backlog}] \leq B_{\max}.$$

Esse comportamento é esperado, pois uma das variáveis passa a atuar como um limite inferior para o número de pacotes no buffer.

Em outras palavras, quando  $B_{\max} < N_{\text{BufferState}}$ , o valor de  $B_{\max}$  impõe uma restrição efetiva sobre  $N_{\text{BufferState}}$ ; de forma análoga, quando  $B_{\max} > N_{\text{BufferState}}$ , a restrição deixa de produzir efeito prático. Como o gráfico está expresso em função de  $N_{\text{BufferState}}$ , é possível observar diretamente as variações decorrentes da alteração de  $B_{\max}$  nos resultados apresentados acima.

Já em relação ao throughput agregado x backlog médio, temos:




Figure 7: Trade-off: throughput x backlog médio

## Parte 4 - Resumo e Conclusões da Análise Paramétrica

Investigamos como variações em parâmetros chave do sistema afetam o desempenho dos modos Cooperativo (Team) e Não-Cooperativo (Nash) em termos de throughput agregado e backlog médio, sob uma restrição de  $B_{max} = 3.0$ .

### Probabilidade de Chegada (ArrProb)

- Throughput:** Aumenta consistentemente com o **ArrProb** (de 1.11 para 1.42), indicando maior aproveitamento do sistema com mais demanda.
- Backlog:** Permanece próximo ao limite  $B_{max} = 3.0$ , mostrando que a restrição é ativa.
- Ganhos da Cooperação:** O modo cooperativo apresenta um throughput ligeiramente superior (ganhos modestos de 0.006 a 0.019) em comparação ao não-cooperativo.

### Limites de Potência (v1, v2)

- Throughput:** Aumentar os limites de potência eleva o throughput (de 1.20 para 1.47), pois os jogadores podem transmitir com mais energia.
- Backlog:** Mantém-se no limite  $B_{max} = 3.0$ .
- Ganhos da Cooperação:** Consistentes, mas pequenos (cerca de 0.008 a 0.01) sobre o caso não-cooperativo.

### Número de Estados de Canal (NLinkStates)

- Throughput:** Contrariando a intuição, um aumento nos **NLinkStates** (de 3 para 6) reduziu o throughput agregado (de 1.42 para 1.31).
- Backlog:** Permanece em 3.0.
- Interpretação:** Uma maior granularidade de estados não resultou em melhor desempenho sob as condições atuais ( $B_{max}$  e potência), talvez devido à complexidade da política ou à forma como a capacidade é distribuída.
- Ganhos da Cooperação:** Minúsculos, na ordem de milésimos.

### 4. Tamanho do Buffer (NBufferStates)

- Backlog:** Para **NBufferStates=6**, o backlog ficou ligeiramente abaixo do limite (2.873), mas para tamanhos maiores (8 e 10), ele saturou em 3.0.
- Throughput:** Variou pouco (aproximadamente 1.372 a 1.379).

- **Interpretação:** Quando a restrição de backlog é dominante, aumentar a capacidade do buffer tem impacto limitado, pois o sistema já opera para manter o atraso sob controle.

A restrição de backlog médio ( $B_{max} = 3.0$ ) emerge como um fator crítico que domina o comportamento do sistema. O backlog real quase sempre satura nesse limite, o que leva a políticas de admissão mais conservadoras (rejeitando pacotes mais cedo) para evitar o acúmulo excessivo. Os ganhos de throughput são impulsionados principalmente por parâmetros que aumentam a capacidade intrínseca do sistema (como `ArrProb` e limites de potência).

O modo cooperativo é consistentemente superior ao não-cooperativo, mas a magnitude desses ganhos é reduzida quando a restrição de backlog é muito apertada. Isso ocorre porque a prioridade de controlar a fila limita a agressividade com que ambos os jogadores podem otimizar o throughput, independentemente de estarem cooperando ou não. Para observar diferenças mais acentuadas entre os modos, seria necessário relaxar a restrição de  $B_{max}$  ou explorar cenários com diferentes custos de potência e interferência.